Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Институт компьютерных наук и кибербезопасности

Защита курсовой работы

по дисциплине
“Наука о данных и аналитика больших объемов информации”

на тему
“Анализ логистических данных транспортно-экспедиторской компании для автоматизации расчёта коммерческих предложений”

Зинкин Станислав
Неянин Вадим
Алмаметов Эмиль
Сафронов Герман

Санкт-Петербург, 2025

Актуальность проекта

- **Трудоёмкость и ошибки**. Подготовка коммерческого предложения требует обработки большого объёма разнородных данных (груз, маршруты, тарифы, валюта), что при ручной работе ведёт к высоким затратам времени и риску ошибок;
- **Сложность оценки рентабельности.** Разрозненное хранение данных и отсутствие сводных расчётов затрудняют оперативную оценку себестоимости и рентабельности перевозок, а также сравнение альтернативных вариантов маршрутов;
- **Единая система анализа данных**. Использование аналитической платформы позволяет централизованно хранить данные по перевозкам и автоматизировать расчёт стоимости и ключевых показателей коммерческого предложения;
- **Скорость и прозрачность**. Автоматизация расчётов и единые правила обработки данных позволяют сократить трудоёмкость подготовки коммерческого предложения, повысить прозрачность расчётов и снизить влияние человеческого фактора;
- **Возможность роста**. Формирование аналитических отчётов и визуализаций по перевозкам создаёт основу для анализа динамики показателей, выявления узких мест и поддержки управленческих решений на уровне компании.

Цель и задачи

Цель: Сокращение трудозатрат на составление коммерческих предложений с помощью аналитических методов.

Основные задачи:

- Обработка и подготовка данных из 1С (Excel) и очистка дублирующихся и некорректных строк;
- Импорт подготовленных данных в Elasticsearch и создание индекса с корректными типами данных;
- Визуализация ключевых показателей деятельности: число грузов, вес, объём, выручка, маржа, расходы, загруженность менеджеров и логистов;
- Создание интерактивных дашбордов и аналитических панелей в Kibana с фильтрацией по датам, клиентам, странам, способам доставки и статьям затрат.

Цели аналитики

- Расчет минимальных, средних и медианных значений маржи, тарифа и иных параметров:
- Нахождение коэффициента сезонности по количеству накладных, объемам и весам перевозимых грузов:
- Расчет параметров с группировкой по направлениям, способам доставки, временным интервалам:
- Расчет коммерческого предложения.

Данные

Источник данных: Выгрузка из 1С (конфигурация «1АБ:Карго») в формате Excel.

Объем данных:

- 38 704 строк;
- 81 столбец;
- Период с 01.01.2025 по 30.06.2025;
- 11 Мб.

Накладная	Вес, кг	LDM	Число коробок	Габариты груза	Валюта страховой стоимости	Страховая стоимость
25-01-H0000000004	123,000	0,118		48*30*25cm/6, 38*38*35cm, 32*22*12cm/2, 44*30*35cm, 60*43*18cm, 52*62*41cm, 59*40*26cm, 48*30*14cm	USD	80 418,02
25-01-H0000000004	123,000	0,118		48*30*25cm/6, 38*38*35cm, 32*22*12cm/2, 44*30*35cm, 60*43*18cm, 52*62*41cm, 59*40*26cm, 48*30*14cm	USD	80 418,02
25-01-H0000000005	251,000	0,268				
25-01-H0000000005	251,000	0,268				
25-01-H0000000005	251,000	0,268				
25-01-H0000000005	251,000	0,268				
25-01-H0000000005	251,000	0,268				
25-01-H0000000005	251,000	0,268				
25-01-H0000000006	566,000	0,400		120x80x74	руб.	393 871,93
25-01-H0000000006	566,000	0,400		120x80x74	руб.	393 871,93
25-01-H0000000006	566,000	0,400		120x80x74	руб.	393 871,93
25-01-H0000000006	566,000	0,400		120x80x74	руб.	393 871,93
25-01-H0000000006	566,000	0,400		120x80x74	руб.	393 871,93

Рисунок 1. Пример данных

Особенности и проблемы данных:

- Дублирование строк по накладной и рейсу;
- Связь «одна накладная – несколько рейсов» и наоборот;
- Неструктурированные габариты груза (текстовый формат);
- Частично отсутствующие объемы и габариты;
- Разные валюты (RUB, USD, EUR, CNY), включая составные форматы;
- Зашифрованные справочники клиентов и сотрудников.

Архитектура решения

Используемый стек:

- ELK Stack: Elasticsearch + Kibana;
- Python для обработки и загрузки данных;
- Docker Compose для контейнеризации и развертывания компонентов.

Компоненты системы:

- Контейнер Elasticsearch — хранение и быстрый поиск логистических данных;
- Контейнер Kibana — визуализация показателей и аналитические дашборды;
- Контейнер Python-приложения — подготовка данных, расчёт метрик и загрузка в Elasticsearch.

Поток данных:
Excel (выгрузка из 1С) → CSV (очистка и нормализация данных) → NDJSON (формат для bulk-загрузки) → Elasticsearch (индексация данных) → Kibana (дашборды и аналитика).

Подготовка данных

Очистка и нормализация данных:

- Удаление дубликатов строк по связке накладная – рейс;
- Приведение числовых полей к единому типу (вес, объём, LDM);
- Обработка пропусков и некорректных значений;
- Нормализация текстовых полей (города, страны, форматы дат).

Пример преобразования данных:

Показатель	До обработки	После обработки
Габариты груза	46x41x31 cm (6)	0.116 LDM
Объём	Текстовое поле	0.578 CBM
Валюта	USD / EUR / CNY	RUB

Оценка данных

- **Неполнота**
  В некоторых используемых столбиках отсутствует **~20%** данных.

- **Качество**
  Столбик ‘Габариты груза’, используемый для расчета коммерческого предложения содержит **~1000** вариаций (~3% от общего кол-ва строк) записи габаритов. Названия городов написаны по-разному.

- **Несогласованность**
  Ячейки столбика ‘Габариты груза’ иногда содержат данные другого столбца, что приводит в итоге в несовпадению.

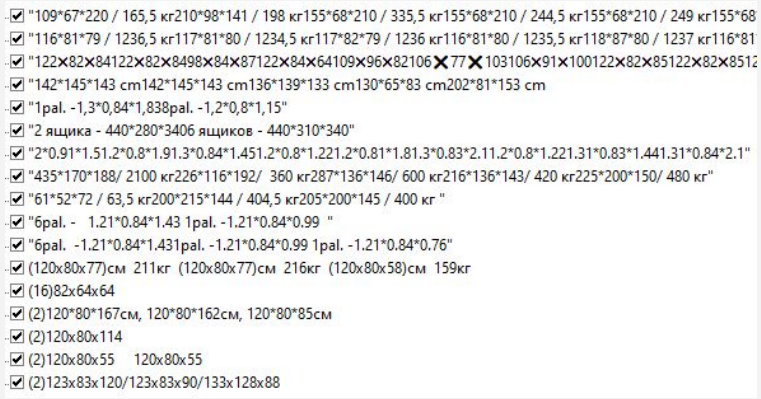

Рисунок 2. Вариации габаритов

Применяемые методы при обработке

- **Регулярные выражения (всего 12)**

  Некоторые группы габаритов отдаленно имеют одинаковый формат;

  Для размеров вида 100x50x30 см (5):

  ```
  r"(\d+[,.]?\d*)\s*[*x]\s*(\d+[,.]?\d*)\s*[*x]\s*(\d+[,.]?\d*)\s*(?:cm|m)?\s*\(\s*(\d+)\s*\)"
  ```

  Для размеров вида 5 паллет 120x80x90:

  ```
  r"(\d+)\s*(?:палл|кор|шт|pallet|box).*?(\d+)[*x]\s*(\d+)[*x]\s*(\d+)"
  ```

- **XML-запросы в ЦБ РФ**

  Для конвертации валюты используется дата накладной и данные из ЦБ РФ;

- **Словари замены**

  Транслитерация некоторых названий городов происходит неверно, есть необходимость использования словарей.

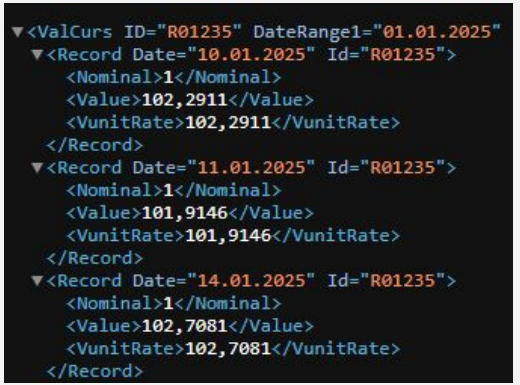

Рисунок 3. XML-запрос в ЦБ РФ

Импорт данных в Elasticsearch

```
# If we do not specify the date type for individual fields,
# they will be of the text/keywords type.
mapping = {
    "mappings": {
        "dynamic": True,  # the remaining fields are determined automatically
        "properties": {
            "Дата накладной": {"type": "date", "format": "dd.MM.yyyy"},
            "Плановая дата начала": {"type": "date", "format": "dd.MM.yyyy"},
            "Плановое время начала": {"type": "date", "format": "HH:mm"},
            "Плановая дата завершения": {"type": "date", "format": "dd.MM.yyyy"},
            "Плановое время завершения": {"type": "date", "format": "HH:mm"},
            "Фактическая дата начала": {"type": "date", "format": "dd.MM.yyyy"},
            "Фактическое время начала": {"type": "date", "format": "HH:mm"},
            "Фактическая дата завершения": {"type": "date", "format": "dd.MM.yyyy"},
            "Фактическое время завершения": {"type": "date", "format": "HH:mm"},
        },
    }
}
```

Рисунок 4. Задание mapping для полей даты и времени

Без явного mapping поля с датами и временем автоматически интерпретируются как текстовые, что делает невозможным использование временных фильтров и временных агрегаций.

Импорт данных в Elasticsearch

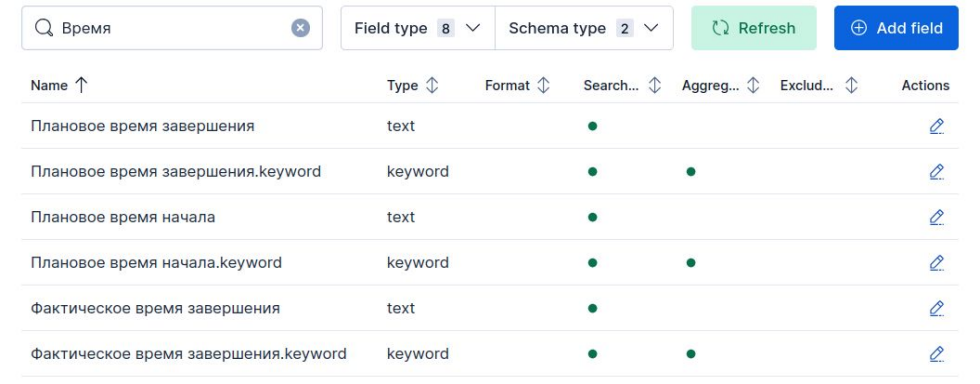

Рисунок 5. Без mapping

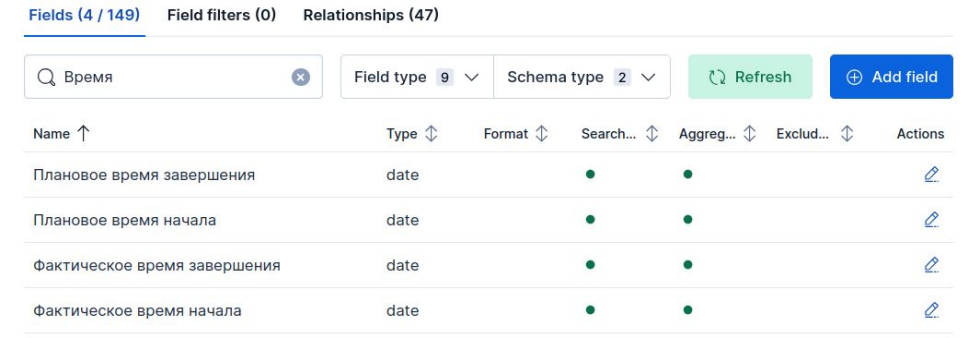

Рисунок 6. С mapping

Импорт данных в Elasticsearch

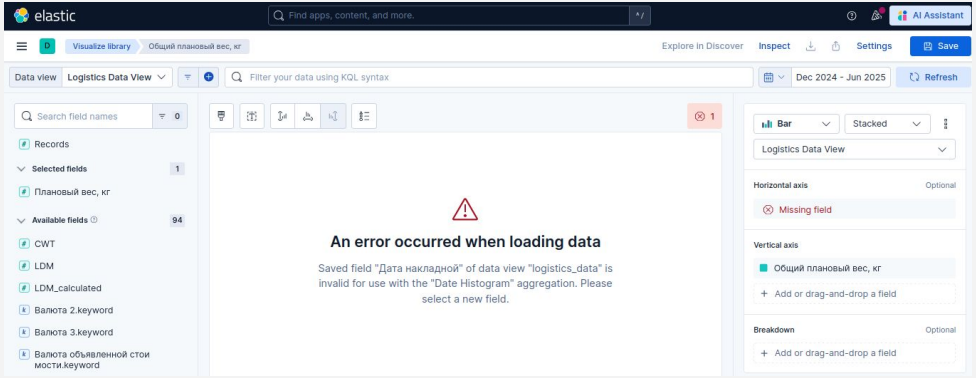

Рисунок 7. Без mapping

Рисунок 8. С mapping

Импорт данных в Elasticsearch

```python
# Indexing documents using Bulk API
actions = []
success_count = 0
error_count = 0

for i, line in enumerate(lines, start=1):
    try:
        doc = json.loads(line)
        actions.append({"_index": INDEX_NAME, "_source": doc})
    except json.JSONDecodeError:
        print(f"\t[{i}] Invalid JSON, skipped.")
        error_count += 1

# Execute bulk indexing
success_count, errors = helpers.bulk(
    es, actions, chunk_size=CHUNK_SIZE, raise_on_error=False
)
error_count = len(actions) - success_count
```

Рисунок 9. Загрузка данных в Elasticsearch с использованием Bulk API

Поштучная индексация создаёт большое количество HTTP-запросов, что резко снижает производительность при больших объёмах данных. Bulk API решает эту проблему за счёт пакетной обработки.

Визуализация в Kibana

```python
# Open the NDJSON file in binary mode
# Important: requests.post with files=... automatically forms multipart/form-data
with open(FILE_PATH, "rb") as f:
    files = {"file": (FILE, f, "application/ndjson")}

    # POST request to the Saved Objects import API
    # Parameter overwrite=true allows overwriting objects if they already exist
    r = requests.post(
        f"{KIBANA_URL}/api/saved_objects/_import?overwrite=true",
        headers=headers,
        files=files,  # pass the file via multipart/form-data
    )

# Print the result of the request
print("\tStatus code:", r.status_code, end="\n\n")
```

Рисунок 10. Импорт сохранённых объектов в Kibana с использованием Saved Objects API

Сохранённые объекты Kibana представляют собой набор настроек визуализаций и дашбордов. Их импорт позволяет быстро развернуть готовую систему визуализации на новых данных или в новом окружении.

Визуализация в Kibana

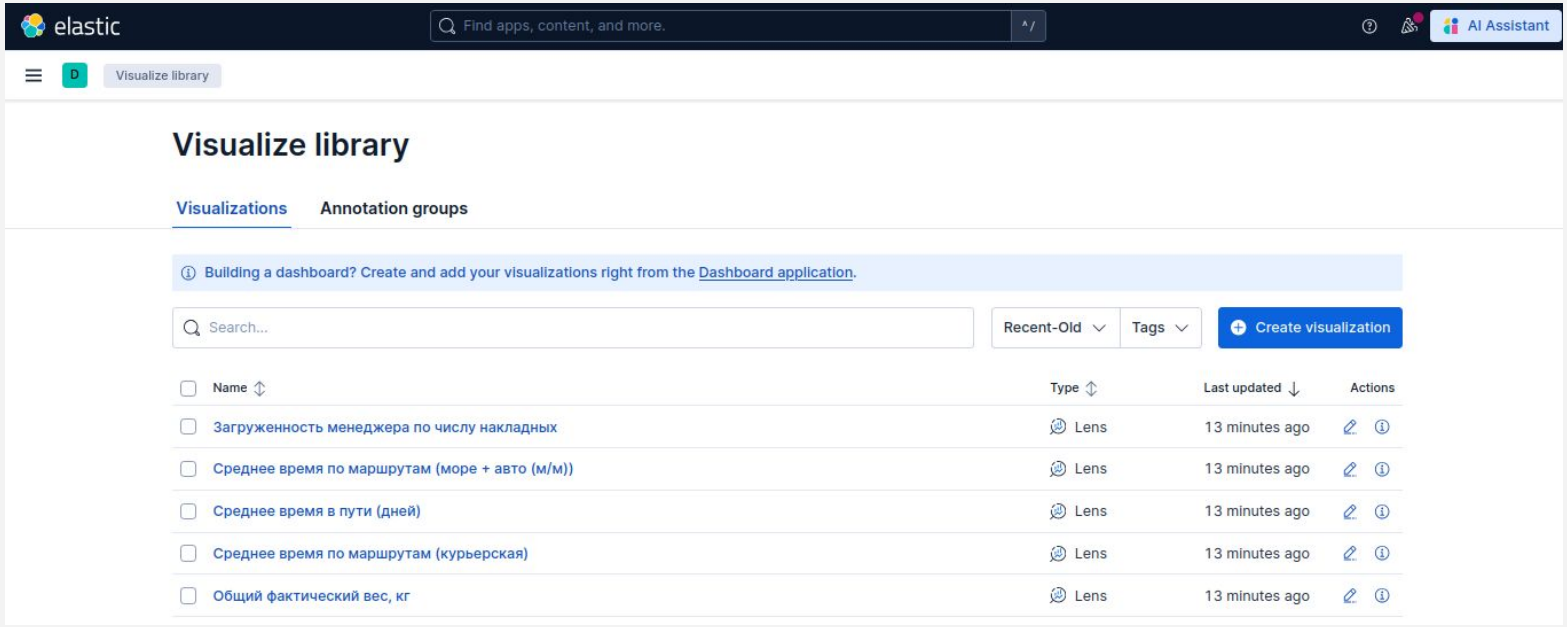

Рисунок 11. Сохранённые объекты: графики

Визуализация в Kibana

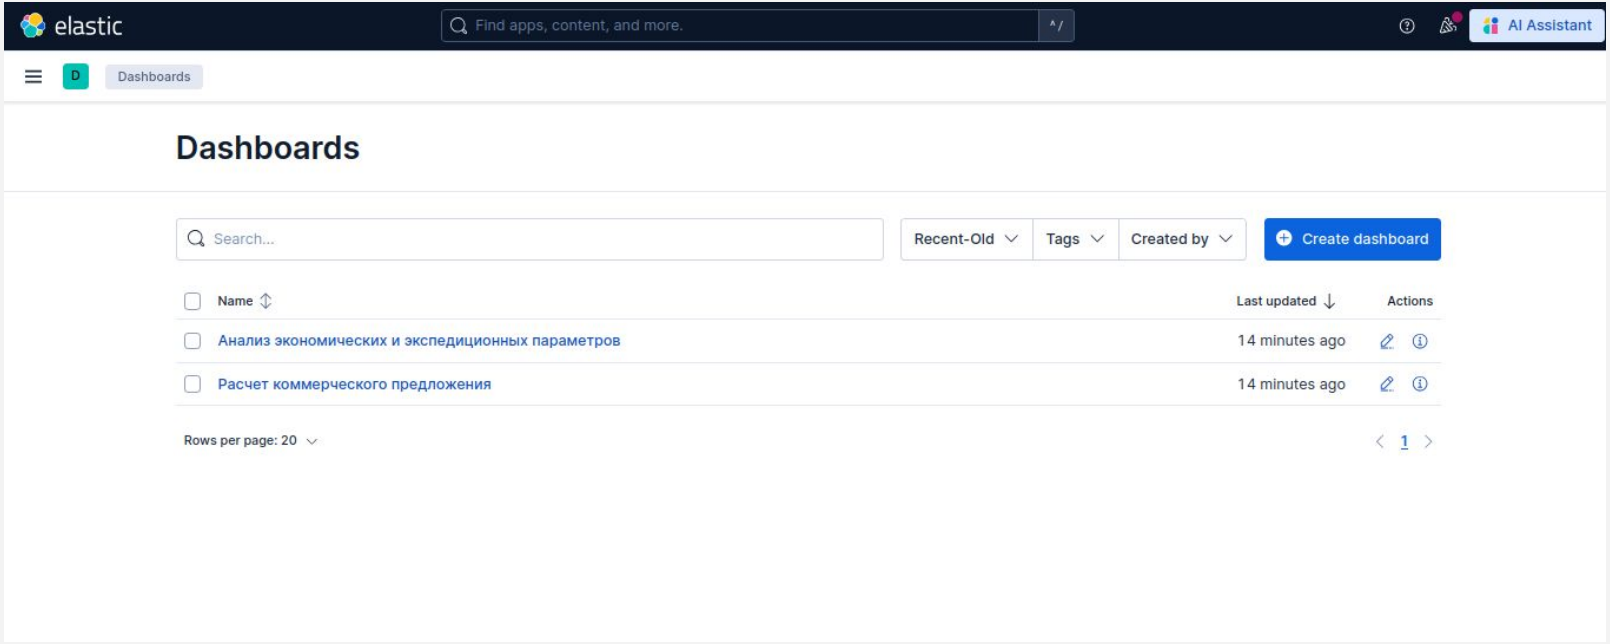

Рисунок 12. Сохранённые объекты: дашборды

Визуализация в Kibana

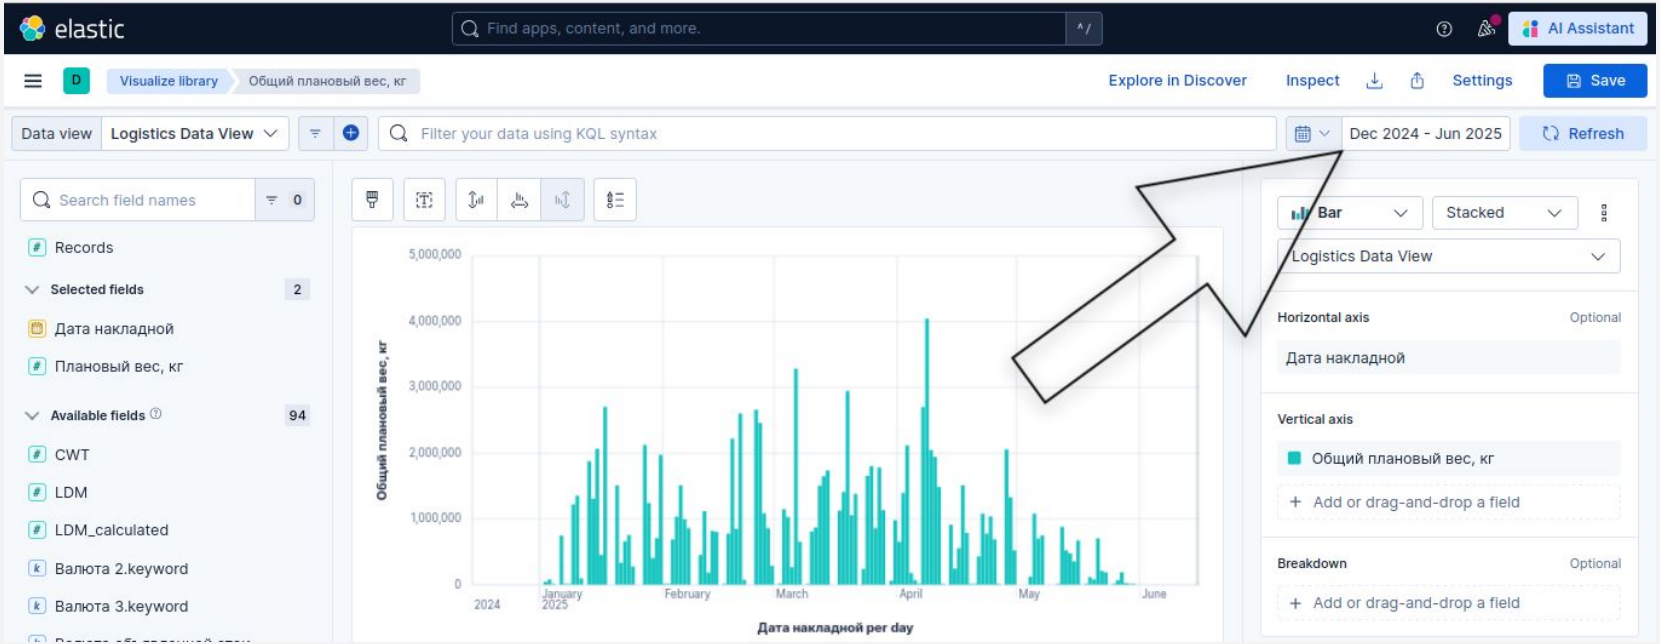

Рисунок 13. Сохранённые объекты: временной фильтр по умолчанию

Визуализация в Kibana

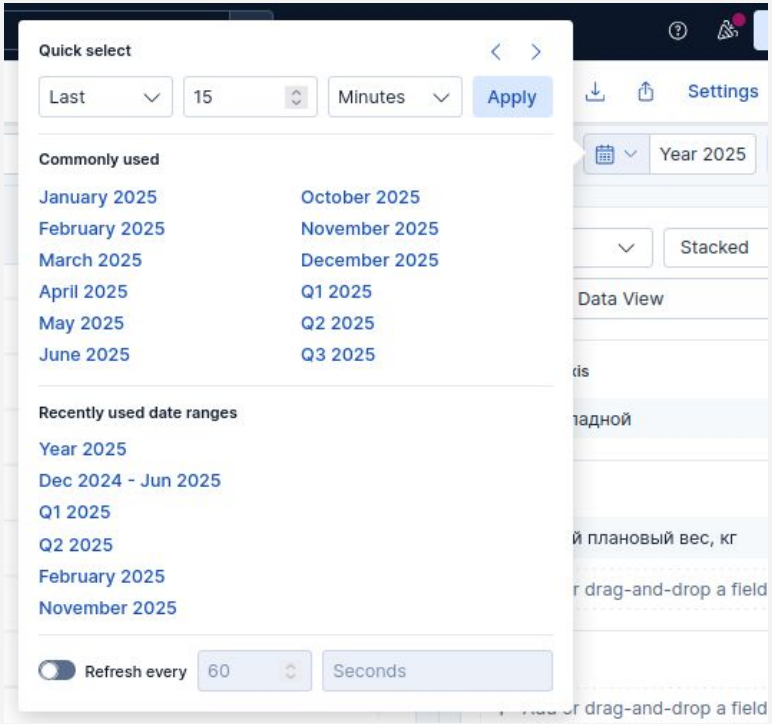

Рисунок 14. Сохранённые объекты: временные фильтры быстрого доступа

Визуализация в Kibana

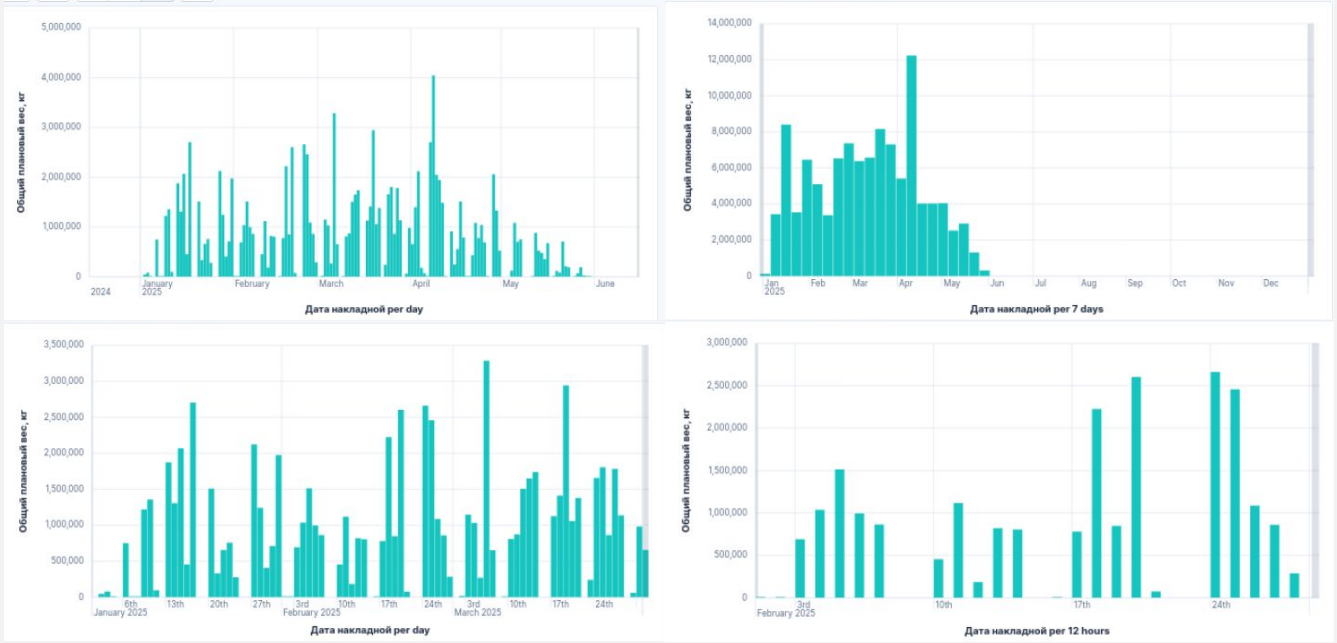

Рисунок 15. Один и тот же график, но с разными временными интервалами

Визуализация в Kibana. Vega

- Создано **57** уникальных визуализаций.
- Визуализации на картинке ниже созданы с помощью **Vega**.

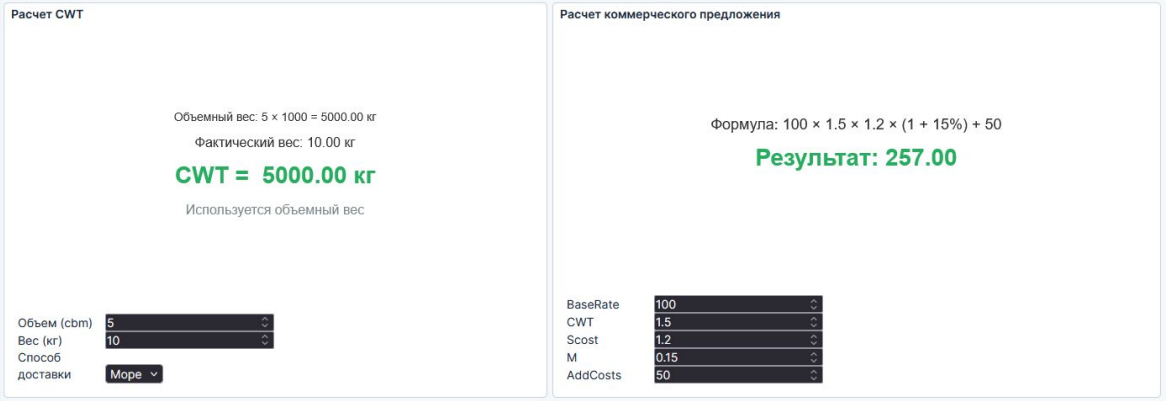

Рисунок 16. Интерактивные визуализации расчета объемного веса и коммерческого предложения

```
"marks": [
  {
    "type": "text",
    "encode": {
      "enter": {
        "align": {"value": "center"},
        "baseline": {"value": "middle"},
        "fontSize": {"value": 18},
        "fill": {"value": "#333"}
      },
      "update": {
        "text": {
          "signal": "'Формула: ' + baseRate + ' × ' + cwt + '
            × ' + scost + ' × (1 + ' + (m * 100) + '%) + ' +
            addCosts"
        },
        "x": {"signal": "width / 2"},
        "y": {"signal": "height / 2 - 40"}
      }
    }
  },
```

Рисунок 17. Фрагмент Vega-кода

Визуализации в Kibana. Lens

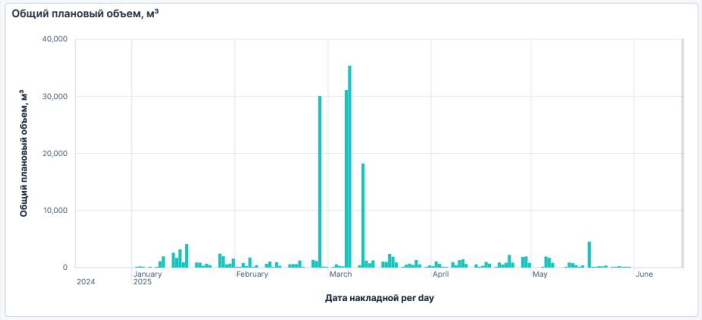

Рисунок 18. Зависимость общего планового объема от даты накладной

Рисунок 19. Зависимость доли каждого вида транспорта от даты накладной

Коэффициенты сезонности

Месяц per month	Коэфф. сезонности по объему	Коэфф. сезоннсти по кол-ву дней доставки	Коэфф. сезонности по весу	Коэфф. сезонности по кол-ву накладных
2024-12-01	(null)	(null)	(null)	0
2025-01-01	0.655	1.047	0.892	1.23
2025-02-01	0.878	1.22	1.097	1.205
2025-03-01	1.882	0.991	1.232	1.469
2025-04-01	0.993	1.051	1.379	1.654
2025-05-01	0.592	0.691	0.4	1.442
2025-06-01	(null)	(null)	(null)	0

Рисунок 20. Коэффициенты сезонности по разным показателям

Рисунок 21. Загруженность менеджеров по числу накладных

Docker Compose и автоматизация

Docker Compose используется для оркестрации всех компонентов аналитического решения и запуска окружения одной командой.

Автоматизация запуска:

- Все сервисы поднимаются одной командой `docker compose up -d`;
- Python-приложение ожидает готовности Elasticsearch и Kibana;
- Полный пайплайн (подготовка данных → загрузка → визуализация) выполняется без участия пользователя.

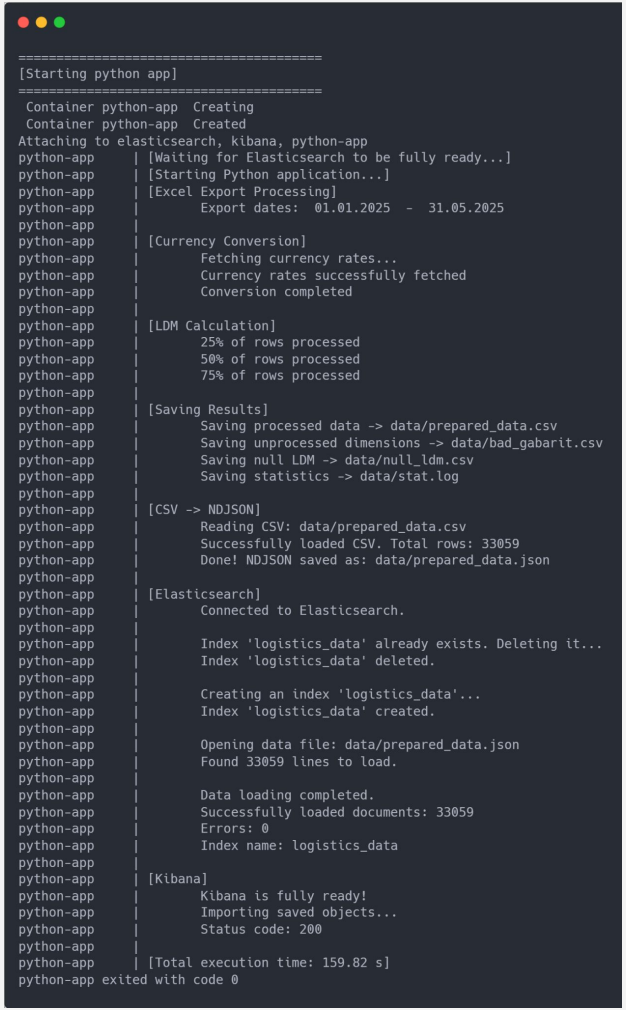

Рисунок 22. Полный пайплайн

Docker Compose и автоматизация

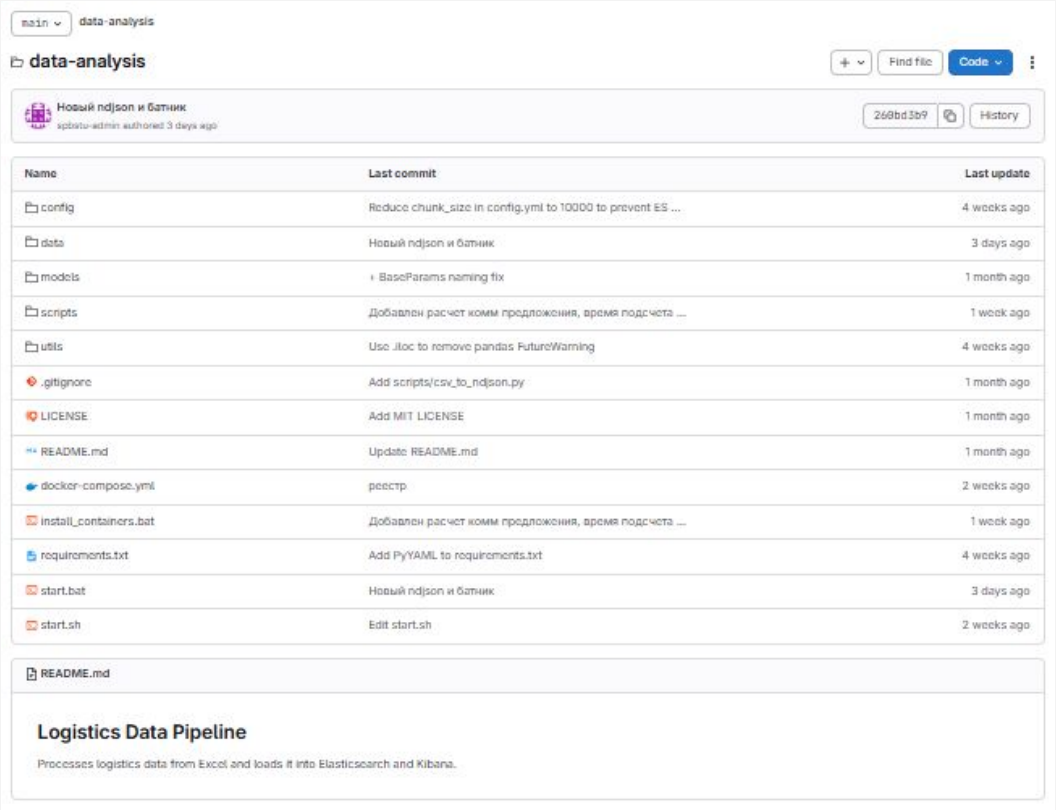

Рисунок 23. Репозиторий GitLab

Docker Compose и автоматизация

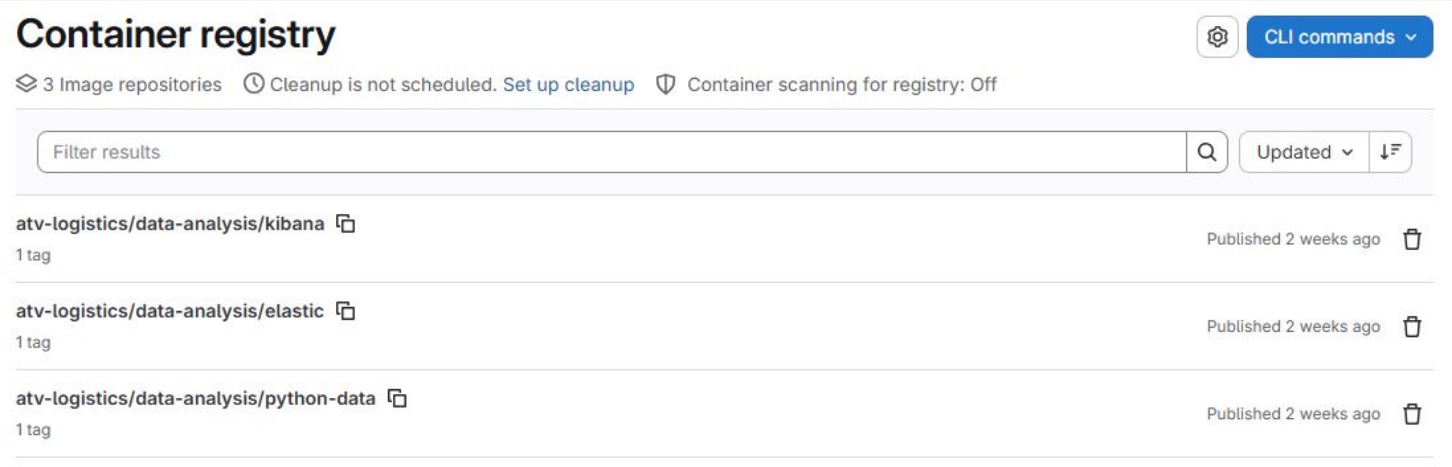

Рисунок 24. Образы Elasticsearch, Kibana и Python в Gitlab Container Registry

Горизонтальное масштабирование

Elasticsearch обладает возможностью линейного масштабирования.

- **Чтение**
  Механизм: Запросы выполняются параллельно на всех шардах
  Результат: + узлы/реплики → + QPS (~линейно);

- **Запись**
  Механизм: Данные пишутся в разные первичные шарды
  Результат: + первичные шарды → + скорость индексирования;

- **Хранение**
  Механизм: Шарды распределяются по новым узлам
  Результат: + узлы с дисками → + общий объём кластера.

Конечный вид дистрибутива

- Объем ~ 1.3 Гб;
- Архивы контейнеров;
- Скрипт запуска start.bat;
- Папка data с исходной выгрузкой и результатами.

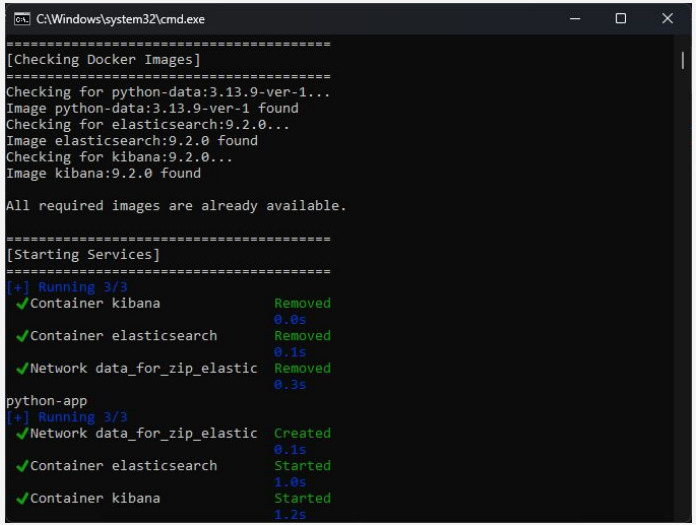

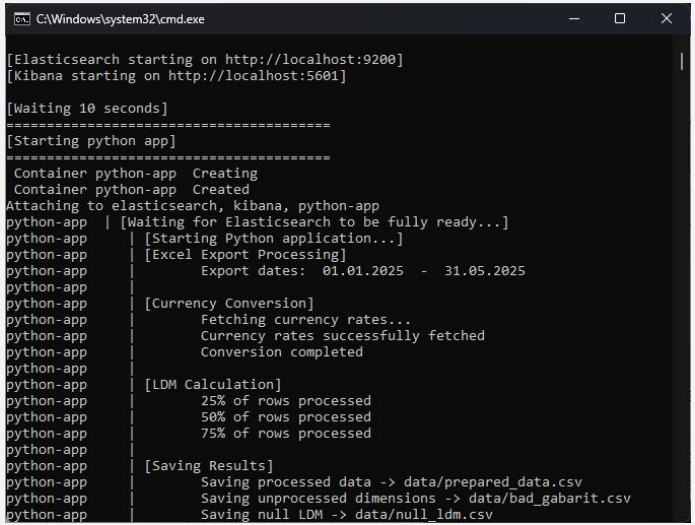


```
.
├── containers
│   ├── elastic.tar
│   ├── kibana.tar
│   └── python.tar
└── data-analysis
    ├── config
    │   └── config.yml
    ├── data
    │   ├── export.ndjson
    │   └── report.xlsx
    ├── docker-compose.yml
    ├── install_containers.bat
    ├── LICENSE
    ├── models
    │   ├── BaseParams.py
    │   └── Invoice.py
    ├── README.md
    ├── requirements.txt
    ├── scripts
    │   ├── calculate_params.py
    │   ├── config_loader.py
    │   ├── csv_to_ndjson.py
    │   ├── generate_test_data.py
    │   ├── import_kibana_objects.py
    │   ├── load_data_to_es.py
    │   ├── main.py
    │   └── prepare_data.py
    ├── start.bat
    ├── start.sh
    └── utils
        ├── converters
        │   ├── model_converters.py
        │   └── type_converters.py
        └── debug_tools.py

9 directories, 26 files
```

Результаты проекта

- Подготовлен дистрибутив и написана документация;
- Написано **~1000** строк программного кода, сделано **67** коммитов;
- Проведено **6** встреч по **~40** минут;
- Построено **57** уникальных визуализаций;
- Рассчитаны основные экономические показатели;
- Приложение работает в контейнерах;
- Реализован автоматический запуск по скрипту;
- Обработка выгрузки за полгода занимает **~150** с.;
- Внедрена возможность выполнения расчета коммерческого предложения.

Спасибо за внимание!
Готовы ответить на вопросы.